STMX VTON TECHNICAL & COST BENCHMARK REPORT

INTERNAL / STMX-BENCHMARK-10000-20261016

의류 상품 10,000벌 Style ID 연산 비용 및 소요 시간 비교 벤치마크

분석 일자	대상 시스템	연산 규모	기준 환율
2026-10-16	STMX VTON /style-ex	상품 10,000벌 (10k Batch)	$1 = 1,400원

Claude Opus 정가	현재 배포 (Opus 캐싱)	Claude 3.5 Sonnet	Qwen-VL-Plus	Gemini 3.8 / 1.5 Flash
약 592만 원	약 163만 원	약 49만 원	약 3.5 ~ 6.9만 원	약 1.7 ~ 3.2만 원
$4,228 (건당 $0.423)	$1,165 (건당 $0.117, -72%)	캐싱 + Batch (-91.7%)	DashScope (-98.8%)	Context Caching (-99.5%)

01 /style-ex 파이프라인 구조 및 1건당 실측 토큰

STMX의 /style-ex 파이프라인은 의류 사진 1장으로부터 4글자 스타일 코드(예: ICSM, ETSD)를 추출하기 위해 **관찰(Vision VLM) → 스코어링 → 판정**의 과정을 수행합니다. 현재 배포 버전은 판정을 로컬 TypeScript 엔진과 규칙 판정표(tc-rules.ts)로 처리하여 **판정 외부 API 비용이 $0**으로 최적화되어 있습니다.

INPUT 상품 대표 이미지 (Public URL / Supabase Storage)
단일 의류 정면 사진 (JPEG/PNG/WEBP, ~1,000-1,600 VLM 토큰 상당)

▼

STEP ① 관찰 (Vision API) — 의류 파라미터 추출 — Claude / Gemini 3.8 / Qwen Vision VLM
- **입력**: 관찰 프롬프트(68,000 토큰) + 이미지 = **실측 68,068 토큰**
- **출력**: 37개 파라미터 · DM 디테일 · 색상 JSON (**약 3,300 토큰**)
- **핵심**: 대용량 프롬프트 캐싱(Context Caching) 여부가 비용의 85% 이상을 좌우

▼

STEP ② 스코어링 (Scoring Engine) — 축 점수 산출 — 서버 내부 TS 엔진 ($0)
- **내부 연산**: EI · SR · DM 3개 축 통계적 스코어링 산출 (소요 시간 ~0.05초)
- 외부 API 호출 없음

▼

STEP ③ 판정 (TC Rules & Judge) — 4글자 코드 확정 — 코드 규칙 판정 ($0)
- **규칙 기반**: tc-rules.ts로 TC(트렌디↔클래식) 판정 및 미결 축 기본값 확정
- *(참고) LLM 판정 사용 시*: 판정 프롬프트 14k 토큰 + 사고 토큰 5k 추가 소요

▼

☆ 최종 Style ID 확정 (4글자 코드: EI · TC · SR · DM → 예: ICSM / ETSD)

• 1건당 토큰 소요 실측치 (기준: docs/product-style-id-extraction-price.md)

파이프라인 단계	수행 모듈 / 엔진	입력 토큰 (실측치)	출력 토큰 (실측치)	API 비용
① 관찰 (Vision)	Vision Language Model	68,068	약 3,300 (2.6k~4.0k)	유상 (모델별 청구)
② 스코어링	로컬 Node.js 엔진 (scoring.ts)	-	-	$0 (서버 로컬)
③ 판정 (현 배포)	규칙 판정 엔진 (tc-rules.ts)	-	-	$0 (코드 판정)

파이프라인 단계	수행 모듈 / 엔진	입력 토큰 (실측치)	출력 토큰 (실측치)	API 비용
③ 판정 (레거시 LLM)	*Claude Opus 5.5 / Gemini Pro*	*14,063*	*약 5,000 (답안+CoT)*	*유상 추가 호출*

02 상품 10,000개 연산 종합 비용 비교 (Claude vs Gemini vs Qwen)

10,000개 상품 연산 시의 공식 API 비용 비교입니다. **Gemini 3.8 Flash** 및 **Gemini 1.5 Flash**는 압도적인 Context Caching 단가($0.01875/1M)로 인해 Claude 정가 대비 **99.5% 이상의 비용 절감** 효과를 제공합니다.

제공사	사용 모델	적용 최적화 옵션	단가 (입력 / 출력 / 캐시)	1건당 비용	10,000벌 (USD)	10,000벌 (KRW)
Claude API	Opus 4.8	캐싱 미적용 (정가 기준선)	$5.00 / $25.00 / -	$0.423	$4,228	약 592만 원
Claude API	Opus 4.8	**관찰 캐싱 (현재 vtron)**	$5.00 / $25.00 / $0.50	$0.117	$1,165	약 163만 원
Claude API	3.5 Sonnet	관찰 캐싱 적용	$3.00 / $15.00 / $0.30	$0.070	$699	약 98만 원
Claude API	3.5 Sonnet	**캐싱 + Message Batches**	비동기 50% 추가 할인	$0.035	$350	약 49만 원
Google Gemini	**Gemini 3.8 Flash**	**Context Caching (강력 권장)**	$0.075 / $0.30 / $0.01875	$0.0023	$22.8	약 3.2만 원
Google Gemini	**Gemini 3.8 Flash**	**캐싱 + Batch API (초특가)**	비동기 50% 추가 할인	$0.0012	$12.0	약 1.7만 원
Google Gemini	Gemini 3.8 Pro	Context Caching (High Reasoning)	$1.25 / $5.00 / $0.3125	$0.038	$378	약 53만 원
Google Gemini	Gemini 1.5 Flash	Context Caching 적용	$0.075 / $0.30 / $0.01875	$0.0023	$22.8	약 3.2만 원
Alibaba Qwen	Qwen-VL-Plus	**Context Caching (DashScope)**	$0.21 / $0.63 / $0.042	$0.0049	$49.4	약 6.9만 원
Alibaba Qwen	Qwen-VL-Plus	**캐싱 + DashScope Batch**	비동기 50% 추가 할인	$0.0025	$25.0	약 3.5만 원
Alibaba Qwen	Qwen-VL-Max	Context Caching 적용	$0.80 / $3.20 / $0.16	$0.0215	$214.5	약 30만 원

• 10,000벌 연산 비용 절감 로드맵 (비용 폭포 분석)

1. 기존 Claude Opus 정가 기준 — 약 592만 원 ($4,228) 기준선 (100%)

→ 2. 현재 배포 (Opus 관찰 프롬프트 캐싱 적용) — 약 163만 원 ($1,165) -72.4% 절감

→ 3. Anthropic 최적화 (Claude 3.5 Sonnet + Batch API) — 약 49만 원 ($350) -91.7% 절감

→ 4. Alibaba Qwen-VL-Plus (DashScope Caching + Batch) — 약 3.5만 ~ 6.9만 원 ($25~$49) -98.8% 파격 절감

→ 5. Google Gemini 3.8 Flash (Context Caching + Batch)	약 1.7만 ~ 3.2만 원 ($12~$23)	-99.5% 극대화 절감

03 상품 10,000개 연산 소요 시간 및 처리율 벤치마크 (Gemini 3.8 포함)

10,000개 상품 연산은 총 3,300만 토큰의 대용량 텍스트 생성을 수반합니다. **Gemini 3.8 Flash**는 향상된 고속 추론 커널과 시각 처리 엔진을 통해 **1건당 10~13초**, 병렬 풀 가동 시 **1시간 이내(약 50분~1시간 10분)**에 10,000건 전체 연산을 완료할 수 있습니다.

• 1건당 응답 지연시간 (Latency) 상세 분석

모델명	초기 응답 (TTFT)	생성 속도 (TPOT)	1건당 순수 생성 시간	속도 평가
Gemini 3.8 Flash	약 0.4 ~ 0.6초	초당 220 ~ 300 토큰	약 10 ~ 13초	최강 속도
Gemini 1.5 Flash	약 0.5 ~ 0.8초	초당 180 ~ 250 토큰	약 12 ~ 16초	최고속
Gemini 3.8 Pro	약 1.2 ~ 2.0초	초당 100 ~ 140 토큰	**약 25 ~ 35초**	보통
Qwen-VL-Plus	약 1.0 ~ 1.8초	초당 90 ~ 130 토큰	약 25 ~ 35초	빠름
Claude 3.5 Sonnet	약 1.5 ~ 2.2초	초당 75 ~ 95 토큰	약 40 ~ 50초	보통
Claude Opus 4.8	약 2.5 ~ 4.0초	초당 40 ~ 50 토큰	약 75 ~ 85초	매우 느림

• 실행 아키텍처별 10,000벌 총 소요 시간 비교

모델명	1. 병렬 워커 풀 (동시 30~50)	2. 공식 BATCH API (클라우드 분산)	3. 단순 순차 실행 (CONCURRENCY 1)
Gemini 3.8 Flash	**약 50분 ~ 1시간 10분** (동시 40건)	**약 1시간 ~ 2시간** (Batch API)	약 30시간 (~1.2일)
Gemini 1.5 Flash	**약 1시간 ~ 1시간 30분** (동시 35건)	**약 1시간 ~ 3시간** (Batch API)	약 38시간 (~1.6일)
Gemini 3.8 Pro	**약 3.5 ~ 4.5시간** (동시 25건)	**약 2 ~ 5시간** (Batch API)	약 80시간 (~3.3일)
Qwen-VL-Plus	**약 2.5 ~ 3시간** (동시 30건 기준)	**약 2 ~ 5시간** (DashScope Batch)	약 83시간 (~3.5일)
Claude 3.5 Sonnet	**약 6 ~ 7시간** (동시 20건 기준)	**약 4 ~ 10시간** (비동기 배치)	약 125시간 (~5.2일)
Claude Opus 4.8	**약 20 ~ 24시간** (동시 10건, TPM 제약)	**약 8 ~ 16시간** (비동기 배치)	약 220시간 (~9.2일, 불가)

⚡ **Gemini 3.8 처리 속도 분석**

Gemini 3.8 Flash는 68,068 토큰 관찰 프롬프트에 Context Caching 적용 시 **TTFT 0.4초대**, 생성 속도 **초당 250+ 토큰**을 유지합니다. 현재 기본 설정으로 심층 추론(Thinking ON)을 가동하여 시각적 모호성이 있는 의복 디테일까지 정밀 검토하며, **최대 65,536 출력 한도**를 확보하여 사고 과정과 전체 JSON envelope가 완벽히 보존됩니다. (필요 시 환경변수로 초고속 Thinking OFF 전환 지원). 동시 30~50개 비동기 워커 가동 시 **약 1시간 ~ 1시간 50분**에 10,000건 전체 연산을 안정적으로 완료할 수 있습니다.

04 3사 심층 평가 및 엔지니어링 구현 가이드

Google Gemini 3.8 / 1.5

초가성비 • 최고속 (1순위)

- **차세대 성능:** Gemini 3.8 Flash는 향상된 비전 추론과 초당 250+ 토큰 생성으로 **1건당 10~13초** 완료.
- **압도적 캐시 단가:** 68k 프롬프트 캐시 읽기 **$0.01875/1M** (Opus 대비 1/270). 10,000건 비용 **1.7만~3.2만 원**.
- **적합한 경우:** 1만~10만 단위 대규모 이커머스 카탈로그 실시간 및 배치 추출 전체.

Anthropic Claude

고정밀 • 프리미엄

- **강점:** 미세한 봉제선, 텍스처, 실루엣 추론 정확도가 가장 우수함. 지시 불이행률 1% 미만.
- **약점:** 68k 프롬프트 캐시 읽기 단가 ($0.30~$0.50)가 높아 10,000건 시 비용 부담(49만~163만 원).
- **적합한 경우:** 카탈로그 메인 플래그십 의류, 고가 명품 의류의 정밀 재검증 단계.

Alibaba Qwen

동아시아 패션 특화

- **강점:** 타오바오/동대문/아시아 의류 쇼핑몰 이미지 데이터셋 학습량이 방대하여 K-패션 인식 우수.
- **비용:** 10,000건 기준 **3.5만~6.9만 원**으로 Gemini에 근접하는 훌륭한 가성비.
- **적합한 경우:** 국내 및 동아시아 도매 사입 의류 대량 처리, 멀티 클라우드 페일오버.

• 대규모 10,000벌 배치 추출 아키텍처 및 체크리스트

1 Context Caching 등록

68,068 토큰 관찰 프롬프트를 Gemini `cachedContents.create`로 사전 등록하여 네트워크 페이로드 90% 절감 및 TTFT 단축.

2 이미지 전달 최적화

이미지 파일을 Base64 문자열로 본문에 인코딩하지 않고, Supabase 스토리지 또는 웹 CDN의 Public URL을 전달하여 대역폭 병목 방지.

3 Bulk DB Insert

Gemini 3.8이 반환한 37개 파라미터 JSON을 로컬 `scoring.ts`에 통과시켜 Style ID 도출 후, PostgreSQL `product_style` 테이블에 1,000건 단위 벌크 삽입.

☆ 엔지니어링 최종 결론 및 권장 방안 (Recommended Next Step)

10,000벌 의상 Style ID 대량 산출에는 **Google Gemini 3.8 Flash + Context Caching (또는 Batch API)** 조합을 채택할 것을 강력 권장합니다.

- **비용 절감**: 기존 Claude Opus 정가 592만 원 대비 **약 1.7만 ~ 3.2만 원**으로 **99.5% 비용 절감** 달성.
- **소요 시간**: 병렬 워커 풀 가동 시 **약 50분 ~ 1시간 10분 내외**에 10,000건 전체 추출 및 DB 적재 완료 가능.
- **대안**: 동아시아/국내 쇼핑몰 의류 특화 인식이 요구될 경우 **Qwen-VL-Plus (약 3.5만~6.9만 원, 2.5~3시간 소요)**를 2순위로 추천합니다.