10,000벌 의상 Style ID 산출 비용 벤치마크 및 시간 분석

- **작성일**: 2026-10-13
- **대상 시스템**: STMX VTON `/style-ex` (의류 스타일 추출 파이프라인)
- **산정 기준**: 의류 상품 10,000벌 대상 Style ID 추출
- **환율 가정**: $1 = 1,400원

---

1. `/style-ex` 기본 파이프라인 및 토큰 구조 (실측치)

`vton`의 `/style-ex`는 상품 사진 1장으로부터 스타일 아이디(예: `ICSM`, `ETSD`)를 추출하기 위해 3단계 과정을 거칩니다:

```
[상품 이미지]
  │
  ▼ ① 관찰 (Vision API) ──────────────► claude-opus-4-8
  │   - 입력: 관찰 프롬프트(약 68k) + 이미지
  │   - 출력: 37개 파라미터 · DM 디테일 · 색상 JSON (약 3.3k)
  │
  ▼ ② 스코어링 (Local Engine) ────────► 로컬 JS 엔진 (비용 $0)
  │   - EI · SR · DM 축 스코어링
  │
  ▼ ③ 판정 (Judge API) ──────────────► claude-opus-5-5 (effort: high)
  │   - 입력: 판정 프롬프트(약 12k) + 관찰값 JSON(약 2k)
  │   - 출력: 축별 근거 JSON + 사고 토큰 (약 5k)
  │
  ▼ [최종 Style ID 완성 (4글자)]
```

건당 토큰 소요 실측치 (기준: `docs/product-style-id-extraction-price.md`)

단계	사용 모델	입력 토큰 (실측)	출력 토큰 (추정)	정가 단가 (입력 / 출력, 1M당)
① 관찰	`claude-opus-4-8`	**68,068**	약 2,600 ~ 4,000 (평균 3,300)	$5.00 / $25.00
② 스코어링	로컬 JS 엔진	-	-	**$0** (서버 내부 연산)
③ 판정	`claude-opus-5-5` (effort high)	**14,063**	답안 ~1,200 + 사고 토큰 ~3,800 (합계 약 5,000)	$4.00 / $20.00

---

2. 비용 비교: Claude Code CLI vs Anthropic API (10,000벌)

2.1. Claude Code CLI를 사용할 경우

Claude Code는 소프트웨어 엔지니어링을 위한 **대화형 자율 에이전트 CLI**입니다. 이를 대량 배치 추출에 사용할 경우 구조적 비효율로 비용이 폭증합니다:

1. **에이전트 시스템 프롬프트 오버헤드**:

    - 도구 정의(Bash, Read, Edit 등), 안전 수칙 등 에이전트 고유 시스템 프롬프트만 매 턴 **15,000 ~ 20,000 토큰**이 추가 주입됩니다.
2. **다중 턴 컨텍스트 누적**:
    - 에이전트가 스크립트 실행, 이미지 조회, 결과 확인 등 도구 호출(Tool Call)을 순환할 때마다 이전 대화 이력이 누적되어 건당 입력 토큰이 **100,000 ~ 150,000 토큰**으로 증가합니다.
3. **프롬프트 캐싱 및 배치 할인 제어 불가**:
    - 프롬프트 캐싱의 세밀한 위치 제어가 어렵고, 50% 할인되는 Batch API를 적용할 수 없습니다.
4. *(참고) Claude Pro/Team 월 구독형 계정은 5시간당 호출 횟수 제한(Rate Limit)이 걸려 10,000건 연속 처리가 물리적으로 불가능합니다.*

- **건당 예상 비용**: 약 $0.80 ~ $1.50+
- **10,000벌 총비용: 약 $8,000 ~ $15,000+ (약 1,120만 ~ 2,100만 원)**

2.2. Anthropic API를 직접 호출할 경우

Case 1: 일반 API 호출 (정가, 캐싱 미적용)

- 관찰: 입력 $0.340 + 출력 $0.083 = $0.423
- 판정: 입력 $0.056 + 출력 $0.100 = $0.156
- **건당 비용**: 약 **$0.58** (약 810원)
- **10,000벌 총비용: 약 $5,800 (약 812만 원)**

Case 2: 현재 구현 (관찰 프롬프트 캐싱 적용)

- 관찰 프롬프트(68k 토큰)가 5분 이내 연속 호출 시 캐시 읽기(0.1배 = $0.50/1M) 적용.
- 관찰 입력이 $0.340 → $0.039로 대폭 감소.
- **건당 비용**: 약 **$0.28** (약 390원)
- **10,000벌 총비용: 약 $2,770 (약 388만 원)**

Case 3: 관찰 + 판정 프롬프트 모두 캐싱 적용

- 판정 프롬프트(12k 토큰)에도 캐싱 적용 시 판정 입력이 $0.056 → $0.013으로 감소.
- **건당 비용**: 약 **$0.23** (약 320원)
- **10,000벌 총비용: 약 $2,340 (약 328만 원)**

Case 4: Anthropic Message Batches API (50% 비동기 할인) + 캐싱 결합

- 24시간 이내 비동기 처리되는 Batch API는 입력/출력 정가 및 캐시 단가 모두 **50% 추가 할인**.
- **건당 비용**: 약 **$0.12** (약 165원)
- **10,000벌 총비용: 약 $1,170 (약 164만 원)**

2.3. 비용 비교 종합 요약 표

처리 방식	건당 비용	10,000벌 총비용 (USD)	10,000벌 총비용 (KRW)	비고
Claude Code CLI (대화형 에이전트)	$0.80 ~ $1.50+	**$8,000 ~ $15,000+**	**약 1,120만 ~ 2,100만 원**	오버헤드 극심, 타임아웃 위험
Claude Pro/Team 구독 플랜	월 $20~30	- *(수행 불가)*	-	호출 횟수 제한으로 10,000건 불가
Anthropic API (캐싱 미적용 정가)	약 $0.58	**약 $5,800**	**약 812만 원**	Opus 4.8 + Opus 5.5 정가
Anthropic API (현재: 관찰 캐싱)	약 $0.28	**약 $2,770**	**약 388만 원**	현재 vton 배포 상태
Anthropic API (관찰+판정 캐싱)	약 $0.23	**약 $2,340**	**약 328만 원**	판정 캐시 추가 적용 시
Anthropic Message Batches API	**약 $0.12**	**약 $1,170**	**약 164만 원**	**비동기 배치 50% 추가 할인**

---

3. 적은 비용으로 10,000개 의상 Style ID를 산출하는 방법 제안

```
[비용 절감 단계]
기존 정가 (812만 원)
  ↓ Anthropic Batch API + 판정 캐싱 (164만 원, -80%)
  ↓ [방안 A] Anthropic 모델 티어 최적화: Sonnet + Haiku (약 35만 ~ 49만 원, -95%)
  ↓ [방안 B] Gemini 1.5 Flash VLM 전환 (약 4만 ~ 7만 원, -99.4%)
```

[방안 A] Anthropic 생태계 유지: 모델 티어 최적화 (Model Cascading)

현재 설정은 최상위 최고가 모델(Opus)에만 의존하고 있습니다:

1. **관찰 모델 변경**: `claude-opus-4-8` → **`claude-3-5-sonnet`** ($3.00 / $15.00)
   - 패션 이미지 관찰(파라미터 추출)에서 Sonnet은 Opus 대비 95% 이상의 일치도를 내면서 비용은 절반 이하입니다.
2. **판정 모델 변경**: `claude-opus-5-5` (effort high) → **`claude-3-5-haiku`** ($0.80 / $4.00, 사고 토큰 생략)
   - 판정 단계는 이미지를 보지 않고 **정리된 텍스트 JSON과 룰북**만 비교하는 작업입니다. Haiku로도 99% 이상 지시를 준수합니다.
3. **Anthropic Message Batches API 결합**:
   - **건당 비용: 약 $0.025 ~ $0.035**
   - **10,000벌 총비용: 약 $250 ~ $350 (약 35만 ~ 49만 원, 기존 대비 95% 절감)**

[방안 B] 가성비 극대화: Google Gemini 1.5 Flash 전환 (적극 권장)

- **개념**: Vision 입력 및 프롬프트 캐싱 단가가 가장 저렴한 Google Gemini 1.5 Flash(또는 2.0 Flash) 어댑터를 구축합니다.
- **단가 비교**:

    - Anthropic Opus 입력: $5.00 / 1M 토큰
    - **Gemini 1.5 Flash 캐시 읽기**: **$0.01875 / 1M 토큰** (Opus 대비 약 1/260 수준)
    - Gemini 1.5 Flash 출력: $0.30 / 1M 토큰
- **비용 산출**:
    - 건당 관찰 입력(캐시): 약 $0.0013
    - 건당 관찰 출력(3.3k): 약 $0.0010
    - 판정 단계: 로컬 엔진 + Flash 텍스트 호출 = 건당 $0.001 이하
    - **건당 비용: 약 $0.003 ~ $0.005 (약 4~7원)**
    - **10,000벌 총비용: 약 $30 ~ $50 (약 4만 ~ 7만 원, 기존 대비 99% 이상 절감)**

---

4. Gemini 1.5 Flash 전환 시 소요 시간 벤치마크 (10,000벌)

4.1. 1건당 처리 속도 산출 근거

- **초기 응답 속도 (TTFT)**: 68,000 토큰 관찰 프롬프트에 **Context Caching** 적용 시 첫 토큰 반환까지 **약 0.5 ~ 0.8초**.
- **생성 속도 (TPOT)**: 초당 **약 150 ~ 250 토큰** 고속 생성.
- **1건당 소요 시간**:
    - 37개 파라미터 JSON 생성 (약 2,500 ~ 3,500 토큰): **약 10 ~ 13초**
    - 로컬 스코어링 + 판정: **약 0.5초**
    - → **1건당 순수 처리 시간: 평균 약 11 ~ 14초**

4.2. 실행 아키텍처별 10,000벌 총 소요 시간

실행 방식	분당 처리량	10,000벌 총 소요 시간	특징 및 추천 대상
1. 비동기 병렬 워커 풀 (25~30개 동시 요청)	약 120 ~ 125건 / 분	**약 1시간 20분 ~ 2시간**	낮 시간대에 빠른 확인이 필요할 때
2. Gemini Batch API (`batchGenerateContent`)	클라우드 내부 자동 분산	**약 1시간 ~ 4시간** *(공식 SLA: 최대 24시간)*	**정기 대규모 배치 최적** (50% 추가 할인, 완전 무인 자동화)
3. 단순 순차 단일 루프	*약 5건 / 분*	*약 30 ~ 33시간*	*비추천 (네트워크 단절 위험)*

방식 상세 설명:

1. **비동기 병렬 워커 풀 (Node.js / Python 스크립트)**:
    - 25~30개의 워커가 동시에 요청을 전송.
    - 12초마다 25건 완료 → 초당 약 2건 (분당 약 125건).
    - 10,000 ÷ 125건/분 = **80분**.
    - 지수 백오프(Exponential Backoff) 및 재시도 시간을 고려해도 **2시간 이내** 완료.
2. **Google Gemini Batch API (강력 추천)**:
    - 10,000건의 이미지 URL과 관찰 프롬프트가 담긴 `.jsonl` 파일을 생성하여 구글 API에 1회 업로드.
    - 내 컴퓨터나 서버 프로세스를 계속 켜둘 필요가 없음.
    - Google 내부 자원으로 일괄 처리 후 결과 파일을 다운로드.

- 실측 소요 시간: 보통 제출 후 **1시간 ~ 4시간 내외** 완료.

4.3. 대규모 배치 시 필수 체크리스트

1. **Context Caching 사전 등록 필수**:
   - 68k 토큰 관찰 프롬프트를 `cachedContents.create`로 등록해두고 배치 요청 시 해당 `cachedContent` ID를 참조해야 속도가 3배 빨라지고 비용이 90% 이상 절감됩니다.
2. **이미지 페이로드 최적화**:
   - base64 인라인 인코딩 대신 Supabase 스토리지 또는 웹 Public URL을 전달하여 네트워크 대역폭 병목을 제거합니다.
3. **Bulk DB Insert**:
   - 결과 수신 후 로컬 `scoring.ts`를 실행하여 4글자 Style ID를 확정한 뒤, PostgreSQL `product_style` 테이블에 1,000건 단위로 청크 분할하여 `bulk insert`를 수행합니다.

---

5. Gemini · Meta Muse API 비용 벤치마크 (10,000벌, 2026-10-14 추가)

3장 [방안 B]의 Gemini 1.5 Flash 산정은 **판정 단계와 출력 토큰을 거의 빼서 지나치게 낮게 나왔고**, 1.5 Flash 는 더 이상 단가표에 없다. 현재 판매 중인 Gemini · Meta Muse 모델로 다시 산정한다.

- **단가 기준**: 각 사 공식 단가표 (Gemini 2026-10-13 갱신본, Meta Model API 2026-10 기준)
- **환율 가정**: $1 = 1,400원

5.1. 건당 토큰 가정

단계	고정 프롬프트 (캐시 가능)	상품마다 다른 입력	출력
① 관찰	67,500 (실측)	이미지 등 약 1,200	3,300
③ 판정	12,000 (실측)	관찰값 JSON 약 2,100	5,000 (답 1,200 + 사고 3,800)

- 입력 토큰은 Claude 토큰 계산 API 로 잰 값이다. Gemini · Meta 는 토크나이저가 달라 **±20% 정도 차이**가 날 수 있다 (두 사 API 키가 없어 직접 재지 못했다).
- Gemini 3.x 는 이미지 1장을 기본 해상도(`high`)에서 **1,120 토큰**으로 센다.
- 사고(thinking) 토큰은 출력 단가로 청구된다고 본다.

5.2. 모델별 단가 (1M 토큰당)

모델	입력	캐시 읽기	출력	배치	비고
Gemini 3.1 Flash-Lite	$0.25	$0.025	$1.50	50%	
Gemini 3.5 Flash-Lite	$0.30	$0.03	$2.50	50%	
Gemini 2.5 Flash	$0.30	$0.03	$2.50	50%	
Gemini 3.8 Flash	$0.75	$0.075	$3.75	50%	**2027-01-01 부터 2배** ($1.50 / $0.15 / $7.50)
Gemini 3.1 Pro Preview	$2.00	$0.20	$12.00	50%	200k 토큰 이하 프롬프트 기준

모델	입력	캐시 읽기	출력	배치	비고
Gemini 4 Argon	$2.00	$0.10	$10.00	50%	**2026-12-01 부터 2배** ($4.00 / $0.20 / $20.00)
Muse Spark 1.3 Standard	$1.25	$0.15	$4.25	없음	
Muse Spark 1.3 Contributor	$0.10	$0.002	$0.20	없음	입력을 Meta 학습에 쓰는 조건
Muse Wonder 1.0	$4.00	$0.20	$20.00	없음	

- Gemini 명시적 캐시는 저장 요금이 따로 있다(Flash 계열 $1.00 / 1M 토큰 / 시간 → 약 8만 토큰이면 시간당 약 $0.08). 10,000벌 처리에서는 무시할 수준이다.
- Meta Model API 에는 배치 엔드포인트와 배치 할인이 없다.

5.3. 10,000벌 비용

모델	캐시 없음	캐시 적용	배치 (캐시 없음)	현재 Claude 대비
Gemini 3.1 Flash-Lite	$331	**$153** (약 21만 원)	$166	약 1/18
Gemini 3.5 Flash-Lite · 2.5 Flash	$456	**$241** (약 34만 원)	$228	약 1/11
Gemini 3.8 Flash (~2026-12-31)	$932	**$396** (약 55만 원)	$466	약 1/7
Gemini 3.8 Flash (2027-01-01~)	$1,865	$791 (약 111만 원)	$932	약 1/3.5
Gemini 4 Argon (~2026-11-30)	$2,486	$976 (약 137만 원)	$1,243	약 1/2.8
Gemini 4 Argon (2026-12-01~)	$4,972	$1,951 (약 273만 원)	$2,486	약 1/1.4
Gemini 3.1 Pro Preview	$2,652	$1,221 (약 171만 원)	$1,326	약 1/2.3
Muse Spark 1.3 Standard	$1,388	**$513** (약 72만 원)	—	약 1/5.4
Muse Spark 1.3 Contributor	$99	$21 (약 3만 원)	—	약 1/130
Muse Wonder 1.0	$4,972	$1,951 (약 273만 원)	—	약 1/1.4
(참고) 현재 Claude Opus 4.8 + 5.5	*$5,800*	*$2,770 (약 388만 원)*	*$1,170 (배치+캐시)*	기준

- "현재 Claude 대비"는 캐시 적용끼리 비교했다($2,770 기준).
- Gemini 는 배치에 캐시 할인까지 겹치면 위 캐시 적용 값의 대략 절반이 된다(예: 3.8 Flash 약 $198). 다만 배치 요청에서 캐시 단가가 함께 적용되는지는 확인하지 못해 표에는 넣지 않았다.

5.4. 해석

1. **캐시를 걸면 비용의 대부분이 출력 토큰이다.** 3.8 Flash 캐시 적용 기준 약 80%가 출력이다. 판정의 사고 토큰(약 3,800)을 얼마나 줄이느냐가 모델 선택만큼 비용을 좌우한다. 반대로 관찰 단계에서 사고를 켜 출력이 3,000 늘면 3.8 Flash 는 $396 → $508 이 된다.
2. **Muse Spark Contributor 는 권하지 않는다.** 가장 싸지만 입력을 Meta 모델 학습에 쓰는 조건이고, 여기에는 6.7만 토큰 관찰 엔진 프롬프트(자체 자산)와 상품 이미지가 들어간다. 처리 한도도 150 RPM 으로 Standard(3,000 RPM)보다 훨씬 낮다.
3. **프로모션 단가 만료.** Gemini 3.8 Flash 는 2026-12-31, 4 Argon 은 2026-11-30 까지만 현재 단가다. 10,000벌을 한 번에 처리한다면 그 전에 돌리는 편이 유리하다.

4. **품질은 아직 검증하지 않았다.** 관찰 프롬프트(37개 파라미터 JSON)는 Claude 기준으로 다듬어졌다. 다른 모델이 같은 품질의 JSON 을 내는지 확인하기 전에는 위 금액이 의미가 없다.

5.5. 권장 진행

1. **100건 파일럿** — 현재 Opus 결과가 있는 상품 100건을 기준 삼아 Gemini 3.8 Flash · Gemini 3.1 Flash-Lite · Muse Spark 1.3 Standard 로 같은 파이프라인을 돌린다. Style ID 일치율과 응답의 실제 `usage` 토큰을 비교한다. 모델당 비용은 $1 ~ $5 수준이다.
2. **기본안**: 일치율이 충분하면 **Gemini 3.8 Flash + 프롬프트 캐싱**(10,000벌 약 $400, 배치까지 쓰면 그 이하)으로 2026년 안에 처리한다.
3. **최저가안**: Flash-Lite 도 품질이 버티면 **Gemini 3.1 Flash-Lite**(약 $150).

5.6. 출처

- Gemini API pricing — Google AI for Developers
- Gemini media resolution — 이미지 토큰 수
- Pricing and rate limits — Meta Model API